가 을 학 기 A I T e r m P r o j e c t

불량품에 민감한 불량품 예측기

201502077 유 예 지
201601989 김 진 섭
201601998 박 경 신

CONTENTS

1) 프로젝트 주제

- 작업자 데이터를 활용한 불량품에 민감한 불량품 예측기

2) 프로젝트 소개

- 공정 데이터의 양품은 항상 불량품에 비해 많음
- 클래스의 비율 차이가 크면, 제대로 된 모델을 생성 불가
  (클래스 비율이 높은 데이터로 분류)
- 따라서, 불균형 데이터인 공정 데이터를 활용해 불량품을 민감하게 분류하는 모델을 생성하는 프로젝트 진행 계획

3) 프로젝트 기획

1. 변수 선택
   - p-value와 RanfomForest를 활용해 변수 선택

2. 불량품 데이터 생성
   - GAN 활용 : 학습에 많은 어려움이 있어서 해결을 못함.
   - SMOTE 활용 : Over-Sampling을 활용하여 데이터 추가

3. 모델 생성
   - Naïve Bayes : Prior를 활용해 불량품을 선택할 수 있도록 모델 생성
   - MLP : 균형 데이터로 변경 후 MLP 모델 학습

> Problem Definition

문제 정의

- 추진 배경
  - 머신 러닝 기반 품질 문제 사전 예측 연구는 활발히 진행되고 있지만, 특정 분야(반도체)에서만 이루어지고 있으며 작업자에 의존하는 조립 산업 적용을 위한 연구는 부족함.
- 기술적 요인
  - 모델을 생성할 때 많은 변수 중 어느 변수를 사용할 지? (과적합)
  - 불균형 데이터를 활용하여 학습을 할 경우, 비율이 높은 클래스로 선택할 확률이 높음 (모델 생성에 제한)

해결방안 제시(기술적 요인)

- 변수 선택
  - 로지스틱 회귀분석을 통해 얻은 유의 확률(p값)을 활용 (a = 0.05일 경우, a > p-val이면 연관성이 있음)
  - RandomForest분석으로 importance가 적은 변수는 삭제
- 불균형 데이터
  - Synthetic Minority Over-sampling Technique를 활용해 데이터의 균형을 맞춤.

03

“ 데이터 소개 ”

.

- 현대자동차의 협력회사 유라 테크의 자동차 부품을 제작하는 공정 데이터

1. 공정결과 데이터
   총 34266개의 작업 결과, 1175개의 불량품 데이터, 33091개의 양품 데이터

2. 작업자 데이터
   총 37개의 변수, 1128명의 작업자 데이터

공정결과 데이터

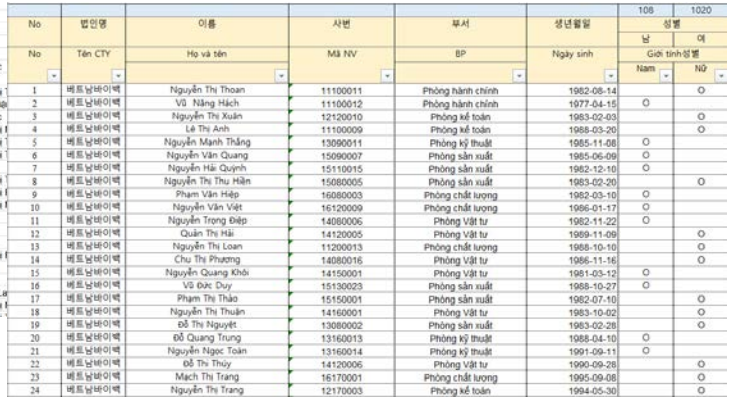

작업자 데이터

데이터 정제

Bad	badCd	ptGroupN	qabDscr	Year	Female	Edu	Skill	Hand	N
1	C0112	MAIN	피복밀림	33	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	35	1	1	2	1	
0	C0112	MAIN	피복밀림	33	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	29	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	29	1	1	2	1	
0	C0112	MAIN	피복밀림	23	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	36	1	1	2	1	
0	C0112	MAIN	피복밀림	24	1	1	2	1	

1) NA 제거

2) 유도변수 생성 : 생년월일 -> 나이

3) 범주형 변수 처리 : 남/여 -> 0 or 1

1) 변수 선택

로지스틱 회귀분석 p-value

	coef	std err	t	P>|t|	[0.025	0.975]
const	0.9305	0.183	5.071	0.000	0.571	1.290
Year	0.0016	0.000	3.769	0.000	0.001	0.002
Female	-0.9547	0.176	-5.411	0.000	-1.300	-0.609
Edu	0.0058	0.004	1.411	0.158	-0.002	0.014
Skill	0.0122	0.008	1.607	0.108	-0.003	0.027
Hand	-0.0139	0.011	-1.276	0.202	-0.035	0.007
NumberofYear	-0.0070	0.004	-1.973	0.049	-0.014	-4.58e-05
Married	-0.0210	0.009	-2.224	0.026	-0.039	-0.002
Chiled	0.0289	0.007	4.361	0.000	0.016	0.042
Pregnancy	0.0394	0.009	4.164	0.000	0.021	0.058
CommutingTime	0.0816	0.009	8.716	0.000	0.063	0.100
Payment	-4.185e-09	4.75e-09	-0.882	0.378	-1.35e-08	5.12e-09
Height	-0.0002	0.000	-1.091	0.275	-0.001	0.000
Weight	0.0013	0.000	3.588	0.000	0.001	0.002
DutyHours	3.375e-05	4.56e-05	0.740	0.459	-5.57e-05	0.000
OverTimeWork	-0.0148	0.004	-3.664	0.000	-0.023	-0.007

P-value 값이 0.05보다 작은 변수 사용

RandomForest분석 - importance

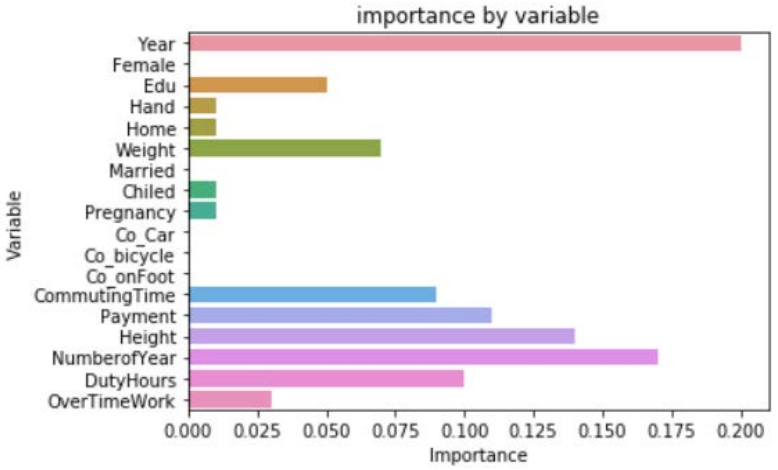

Randomforest 학습 후 importance가 0에 가까운 변수들은 학습에서 제외

2) Naïve Bayes

- Naïve Bayes를 사용한 이유
  불량품 데이터가 양품 데이터에 비해 매우 적음
  따라서, 생성된 모델은 대부분 양품 데이터로 분류
  Prior를 불량품에 더 크게 주어, 불량품에 조금 민감한 모델을 생성
- Prior 비율선정
  양품의 Prior : 0.4, 불량품의 Prior : 0.6

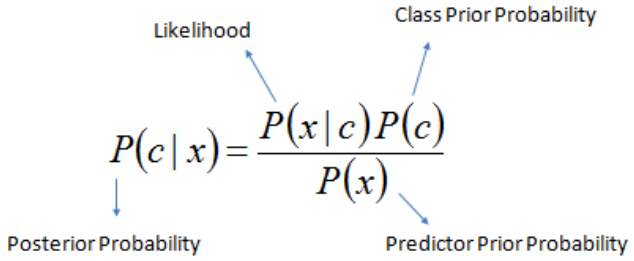

$$P(c|X) = P(x_1|c) \times P(x_2|c) \times \cdots \times P(x_n|c) \times P(c)$$

3) 불량품 데이터 생성

Synthetic Minority Over-sampling Technique(SMOTE)

- Python imblearn.over_sampling 활용

- SMOTE는 Oversampling 기법 중 합성데이터를 활용한 기법

```
After OverSampling, the shape of train_x: (46342, 15)
After OverSampling, the shape of train_y: (46342,)

After OverSampling, counts of label '1': 23171
After OverSampling, counts of label '0': 23171
```

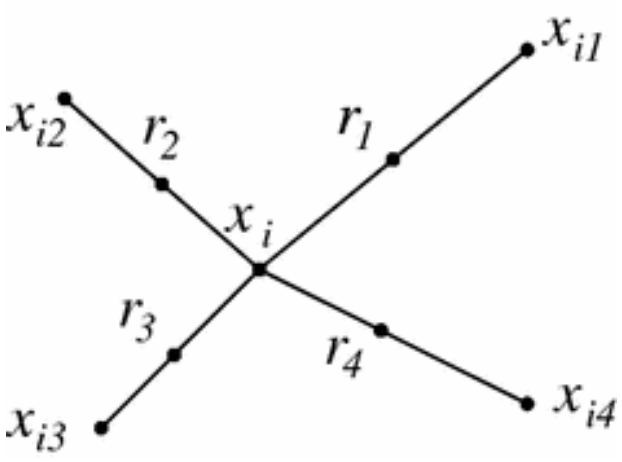

4) MLP Classifier

- Python sklearn 활용

- Hidden layer size : 100,200,300,100

1) Confusion Matrix (Naïve Baysian)

Naïve Baysian (Prior 사용 안함)

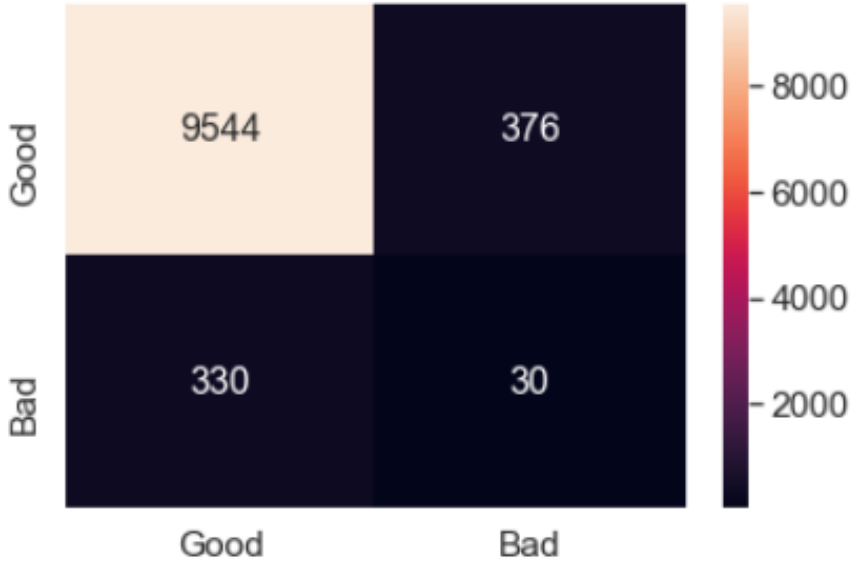

Naïve Bavsian Prior(0.6.0.4)

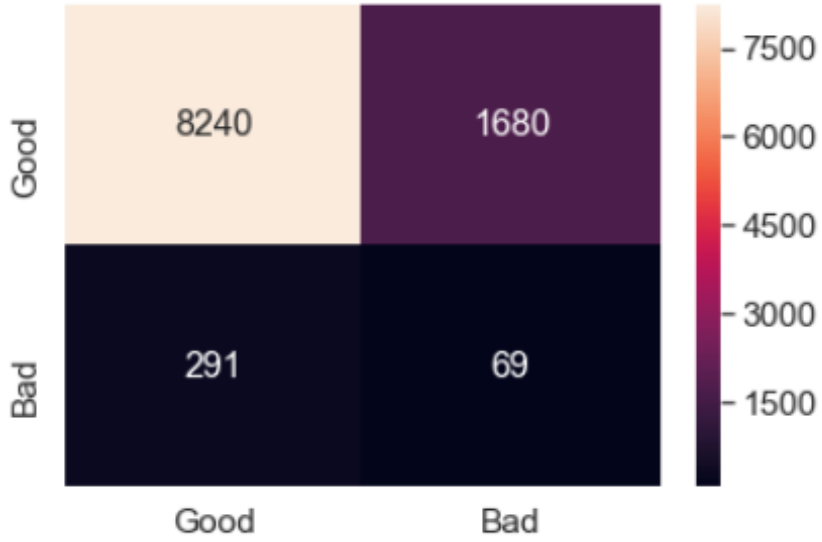

- Naïve Baysian의 Prior를 적용하지 않은 경우와 Prior를 적용한 경우
- 적용하지 않은 경우 Recall : 약 8.3%
- 적용한 경우 Recall : 약 19.2%

1) Confusion Matrix (MLP)

SMOTE 사용 안한 경우

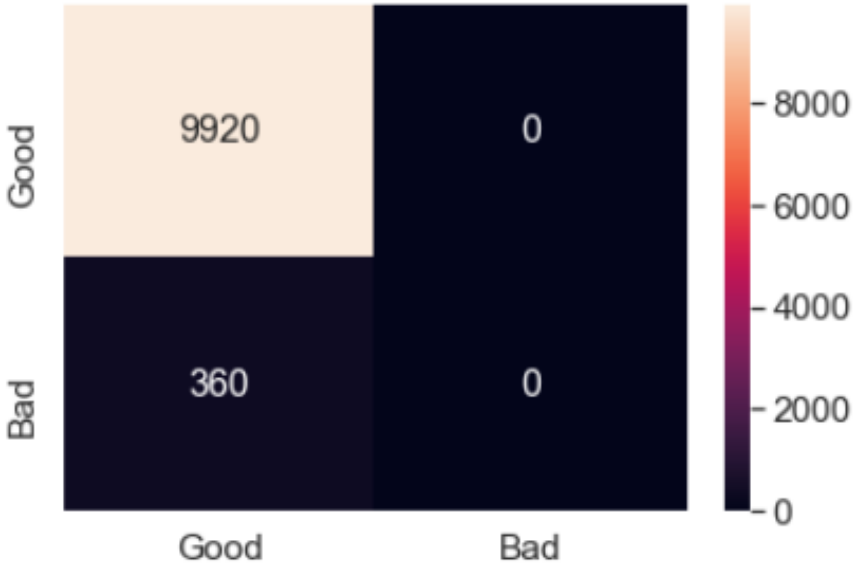

SMOTE를 사용한 경우

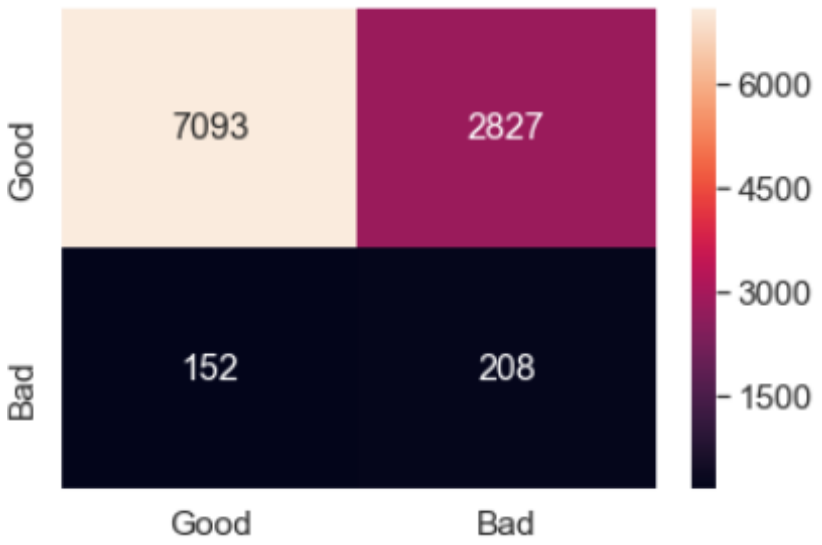

- Naïve Baysian의 Prior를 적용하지 않은 경우와 Prior를 적용한 경우
- 적용하지 않은 경우 Recall : 0%
- 적용한 경우 Recall : 약 58%

2) Accuracy

Naïve Baysian prior(0.6,0.4)

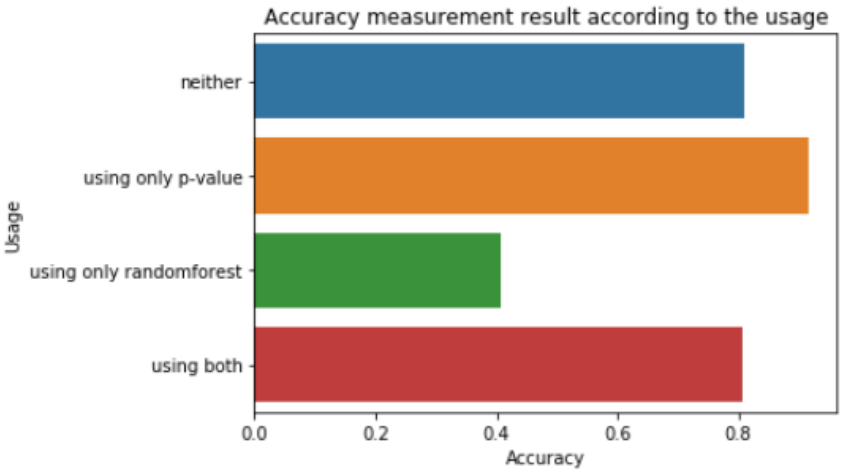

MLP를 활용한 경우

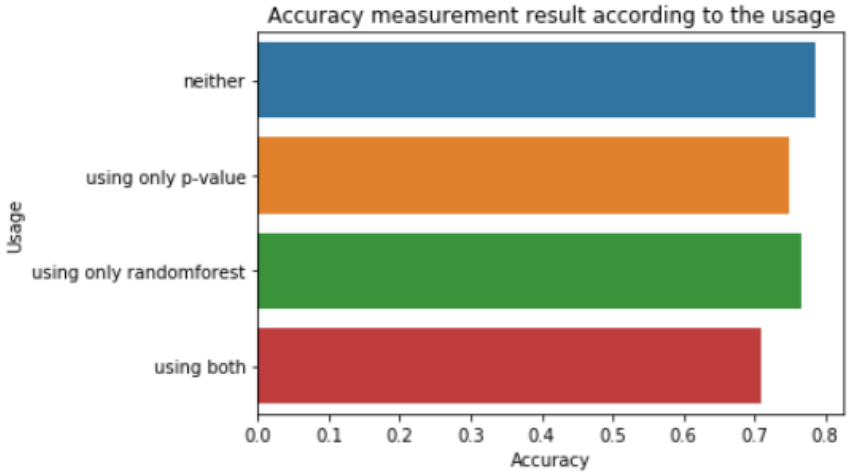

- 모델이 얼마나 잘 맞추었는가?
- 여러가지 변수선택법을 활용하여 분석한 Accuracy
- 위에서부터 변수 선택법을 모두 사용하지 않은 경우, P-value만 활용한 경우, RandomForest만 사용한 경우, 둘 다 모두 사용한 경우
- 정확도만으로는 모델을 분석하기가 어려움

3) Recall

Naïve Baysian prior(0.6,0.4)

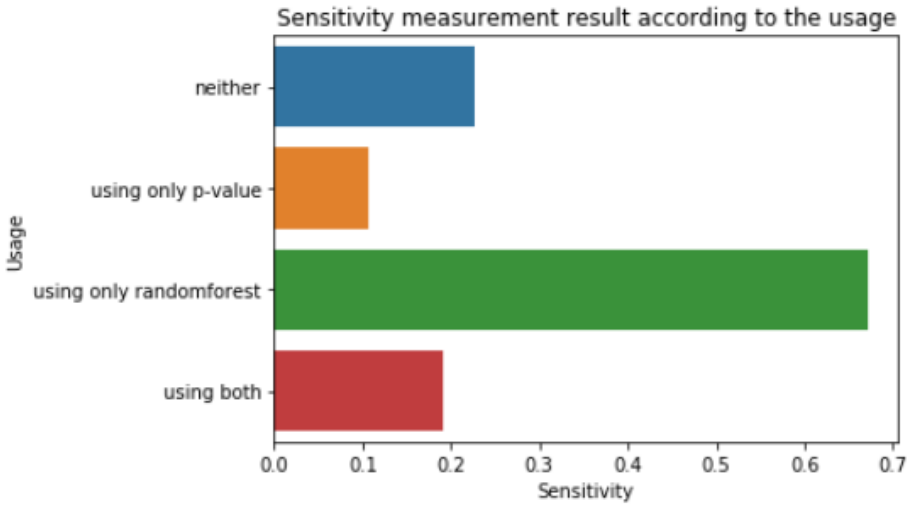

MLP를 활용한 경우

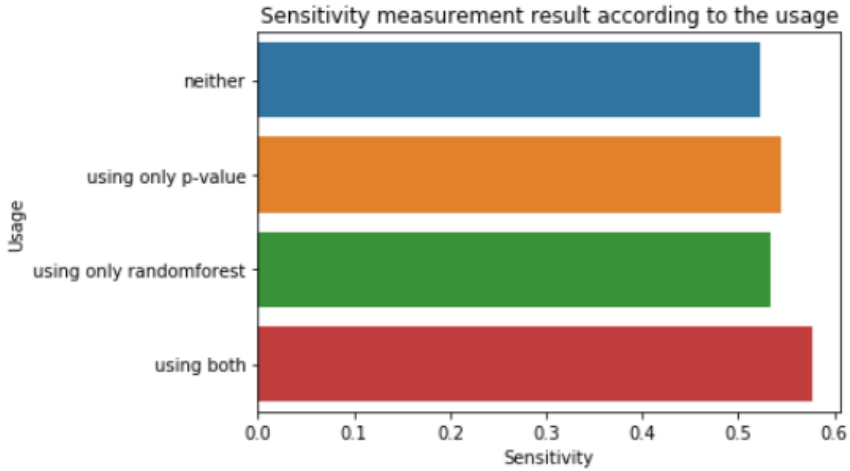

- 실제 불량품을 불량품으로 예측한 비율
- 클 수록 불량에 민감한 모델
- 이것만으로 모델을 평가하기는 어려움(모델이 모두 불량품이라고 하면, 높은 값을 가짐)

4) Precision

Naïve Baysian prior(0.6,0.4)

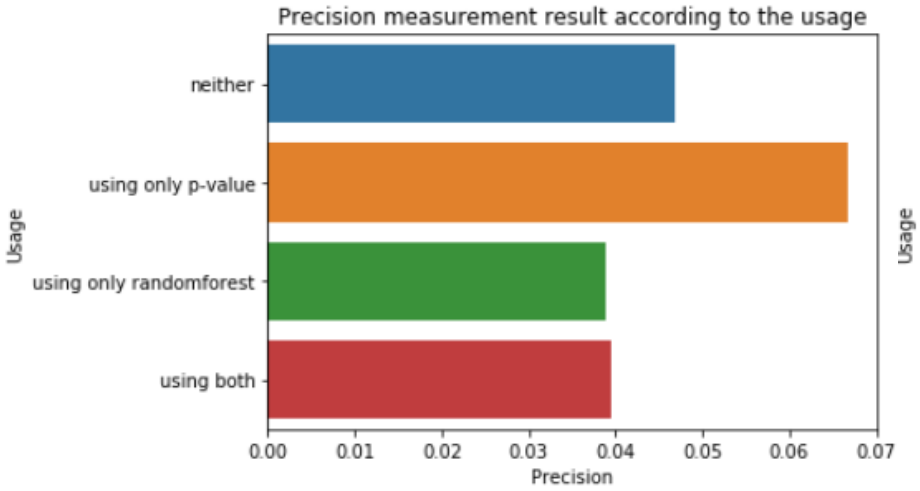

MLP를 활용한 경우

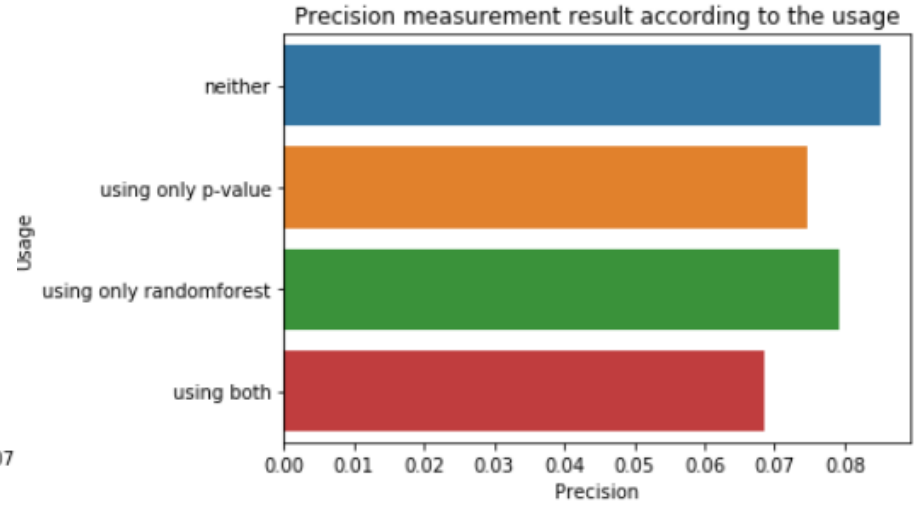

- 불량품으로 검출한 것 중 실제 불량품인 비율

- Recall과 함께 분석을 해보면, p-value와 RandomForest를 활용해 변수를 줄여 학습을 수행하면, 좋은 결과를 기대할 수 있음.(모델의 크기는 줄이고, 그 만큼 성능은 향상 유지 가능)

[텀 프로젝트 결과]

1. 불균형 데이터 문제를 해결하는 방법 : SMOTE
2. 변수 선택법 : Randomforest importance, p-value
3. 변수 선택법을 사용하면 capacity↓, 성능은 유지 및 향상

향후 계획

- GAN 활용 불량 데이터 생성
- 여러 모델 생성(변수선택법 검증)

THANK YOU

인 공 지 능 텀 프 로 젝 트